

ノイズを含む補助変数の下での identifiable VAE の識別可能性

Identifiability of Identifiable VAEs under Noisy Auxiliary Variables

高須賀匠*

Takumi Takasuka

雲居玄道*

Gendo Kumoi

Abstract— The latent space of a variational autoencoder (VAE) changes with each training run, hindering interpretation. The identifiable VAE (iVAE) makes it interpretable and identifiable through an auxiliary variable, but how accurate this analyst-chosen variable must be is unclear. Defining a transition probability matrix between its true and analyst-given values, we show that its rank is the main factor in identifiability: differences among latent distributions conditioned on the given values span a space of dimension one less than the rank, identifiability is lost at rank one, and the rank bounds the settable latent dimension. We assume errors depend only on the true values; the rank is unknown to the analyst.

Keywords— Identifiability, Variational Autoencoder, Auxiliary Variable, Label Noise, Rank of Transition Probability Matrix

1 はじめに

観測データ x の背後に低次元の潜在変数 z を仮定し、 x から z を取り出す枠組みを表現学習という。表現学習では、同じデータ・同じモデル・同じ目的関数であっても、乱数の初期値 (seed) を変えるだけで別の表現が得られ、しかもデータへの当てはまりは同程度である。これは実装の不備ではなく数学的な帰結である。実際、Hyvärinen と Pajunen[1] は、潜在変数の独立性のみを仮定した非線形な生成モデルが原理的に識別不能であることを示している。表現を後段の判断根拠に使う場面では、表現が一意でないこと自体が説明可能性の破綻を意味する。学習し直すたびに軸の意味が変わるのでは、軸に解釈を与えられないからである。

これに対し、変分オートエンコーダ (VAE) を拡張した Khemakhem ら [2] の識別可能な VAE (identifiable VAE, iVAE) は、各標本に付随して観測される補助変数 u を導入し、潜在変数の事前分布を $p(z)$ ではなく $p(z|u)$ と条件づける。これにより、一定の条件下で z がアフィン変換を除いて一意に定まる。本稿で識別可能とは、学習を繰り返しても潜在空間がアフィン変換を除いて同じものに定まることをいう。この枠組みは u に二つのことを要求する。 u が観測されること、そして u の値ごとに事前分布が十分に異なること (十分変動性) である。ところがこの条件は、 u として与える値がデータを生成した時点の値そのものであることを暗黙の前提としている。

iVAE を使う分析者 (以下、分析者) が最初に迷うのは、 u に何を指定すればよいかである。時系列の区間番号、観測機器、季節、クラスラベルなど、標本ごとに定まる

属性であれば何でもよい。筆者らの気圧配置分類でも、 u に何を置くかは最初の設計判断だった。どの属性を選んでも、データが生成された時点の値と記録に残る値とは別の過程で定まり、一致する保証はない。たとえば手書き数字では、書いた人の意図と読み取った側の判定は別の過程である。同一の主体でも判断は揺らぐ。機械的に記録される時刻や機器番号でも、時計の設定や識別子の誤記でずれが起こる。ずれの大きさと機構が違うだけで、生成時と観測時の値の対という構造は同じである。

このうちクラスラベルはずれが大きく、公表された測定もある。CIFAR-10N[3] の *worse* ラベルの誤り率は 40.2% に達する。気圧配置分類では、熟練予報士どうしても判定が約 6 割しか一致しない。ただしこの数値は予報士への聞き取りに基づく概算であって、公表値でも通信路を測った値でもない。したがって次の問いが立つ。

観測時の補助変数が生成時の値から食い違うとき、潜在変数の識別可能性はどう劣化するのか。劣化が完全に崩壊に至る点はあるのか。そしてそれは、手元の補助変数の品質から事前に判定できるのか。

最後の問いが工学的な要請である。とくにラベルを集めるには費用がかかるので、そのラベルに投資する価値があるかを学習の前に判定したい。

そこで本稿は、補助変数の生成時の値 u^* と観測時の値 $\tilde{u}$ の対に生成モデルを置く。すなわち、 u^* の事前分布 π と、 u^* から $\tilde{u}$ への遷移確率行列 Λ (情報理論という離散通信路) の 2 成分で対の同時分布を与える。分析者 (iVAE を学習する側) は Λ を推定も補正もせず、事前分布の条件づけに u^* ではなく $\tilde{u}$ をそのまま用いるとする。これは実装上素朴で標準的な使い方である。この設定では iVAE の生成モデルの仮定が満たされないで、既存の識別可能性定理は使えない。そこで、モデル族が真の分布を含まないときに推定が収束する先 (擬似真値) を扱う誤特定 M 推定 [4] の枠組みを用いる。

主定理は、観測時の値ごとに条件づけた潜在分布の差の一次結合全体がなす空間の次元が、遷移確率行列 Λ のランクから 1 を引いた値に等しいことを述べる。完全崩壊は Λ のランクが 1、すなわち観測時の値が生成時の値の情報をもたないときに限り起きる。このとき擬似真値の事前分布は観測時の値によらなくなり、分析者のモデルは事前分布を条件づけない VAE と同じ族になる。ただし主定理はデータの側で区別できる方向の数を述べる。分析者のモデルが表せる方向の数は別の命題で与えられ、ずれがない場合にも両者は食い違いうる (§5.1)。擬似真値における十分変動性には、 Λ のランクが潜在次元 d に 1 を足した値以上であることが必要である。誤り率 ρ だ

* 〒 940-2188 新潟県長岡市上富岡町 1603-1 長岡技術科学大学, Nagaoka University of Technology, 1603-1 Kamitomioka, Nagaoka, Niigata 940-2188, Japan. E-mail: s233319@stn.nagaokaut.ac.jp, kumoi@vos.nagaokaut.ac.jp

けで決まる対称通信路では、崩壊は $\rho = (K-1)/K$ の一点で起きる (K は u^* の取りうる値の個数). これらを、ランクを指定した通信路の計算と、CIFAR-10 で学習した iVAE の事前分布とで確かめる (§5). ただし最後の問いに対しては、判定に何が必要かという条件を与えるにとどまり、判定の手続きは与えない. Λ のランクと π はいずれも分析者に未知だからである.

本稿の構成要素のうち、次の三つは既知である. (i) 通信路の全行の一致と無情報との同値性は、Blackwell の実験比較 [5] や spammer の定義 [6] で用いられている. (ii) 対称ラベルノイズで $\rho = (K-1)/K$ が退化点であることは Angluin と Laird [7] 以来の事実である. Priebe ら [8] はこの点を情報理論的閾値と呼んでいる. (iii) 潜在構造モデルの識別可能性を、クラスごとの条件付き分布を行とする行列の Kruskal ランクで規定することは、Kruskal 以来の古典である [9]. 本稿の新規性は、補助変数を対 $(u^*, \tilde{u})$ として扱ってその対に生成モデルを置き、ずれを潜在連続変数の識別可能性に接続した点にある. 本稿に近い研究として、Saad と Nosratinia [10] は通信路で劣化させた側情報の下での確率ブロックモデルの完全復元を論じているが、対象は離散ラベルである. 非線形 ICA (独立成分分析) の総説 [11] にも、補助変数自体が劣化する場合の記述は見当たらない.

2 従来手法：識別可能な VAE

Khemakhem ら [2] に従い、生成モデルを

$$z \sim p_{T,\lambda}(z | u), \quad (1)$$

$$x = f(z) + \epsilon \quad (2)$$

とする. ここで $z \in \mathbb{R}^d$ は潜在変数, d は分析者が選ぶ潜在次元, f は単射 (デコーダ), ϵ は z と独立な観測ノイズである. 事前分布は条件付き因子分解型指数族

$$p_{T,\lambda}(z | u) = \prod_{i=1}^d \frac{Q_i(z_i)}{Z_i(u)} \exp \left[\sum_{j=1}^k T_{i,j}(z_i) \lambda_{i,j}(u) \right] \quad (3)$$

とする. ここで Q_i は基底測度, Z_i は正規化定数, T は十分統計量, λ は自然パラメータ, k は 1 成分あたりの十分統計量の個数である. 事前分布を条件づける u をスロットと呼ぶ. スロットの値を所与とした z と x の生成の母数 $\theta = (f, T, \lambda)$ は、補助変数の生成則も、 x から z を推すエンコーダ q_ϕ の母数 ϕ も含まない.

識別可能性を次のように定義する.

定義 1 (識別可能性). 同値関係 $\sim$ に対し、スロットのすべての値 u で $p_\theta(x | u) = p_{\theta'}(x | u)$ ならば $\theta \sim \theta'$ となるとき、モデル族は $\sim$ -識別可能であるという.

A を可逆行列, c を定ベクトルとして

$$\theta \sim_A \theta' \iff T(f^{-1}(x)) = AT'(f'^{-1}(x)) + c \quad \forall x \quad (4)$$

を $\sim_A$ と書く. 本稿は $\sim_A$ を扱う. すなわち潜在空間が識別可能とは、学習を繰り返しても z の座標系がアフィン変換を除いて同じものに定まることをいう.

事前分布が u に依存しなければ、 $p(z)$ を保つ可逆な h は無数にあり、 $z' = h(z)$, $f' = f \circ h^{-1}$ としても事前分布も x の分布も変わらない. 依存すれば h はすべての u で式 (3) の形を保つ必要があり、独立な制約が十分な数だけ集まると h はアフィン変換に限られる. この条件が十分変動性、すなわち

$$L = [\lambda(u_l) - \lambda(u_0)]_{l=1}^{dk} \in \mathbb{R}^{dk \times dk} \quad (5)$$

が、 u のある相異なる $dk+1$ 個の値 $u_0, \dots, u_{dk}$ で正則であることである. u と x が従属であること (λ が定数でないこと) は必要だが十分ではなく、 L の列の一次独立性が要る. このとき、以下の定理が成り立つ.

定理 2 (Khemakhem ら). ϵ の特性関数の零点集合が測度零, f が単射, $T_{i,j}$ が一次独立, かつ L が正則であれば、式 (1)–(3) のモデルは $\sim_A$ -識別可能である.

この定理は、スロットに差し込む値が生成時の値そのものであることを前提とする.

u は標本ごとに観測され z の分布を動かせばよく、 x の関数である必要はない. 値の個数 K も設計の側で決まる. よく用いられるクラスラベルは、同じクラスは潜在空間でも近いという事前知識を置きやすい. また、定理 2 が要求する値は相異なる $dk+1$ 個であって、標本ごとの精密な注釈ではない. そのため、少数のクラスに粗く分けるだけで条件を満たしうる. ラベルは分類の教師信号ではなく、 z の分布を動かす手がかりである. 人が判断するからこそ専門知識を注入でき、同じ理由ですれは避けられない. この交換条件が、ラベルを代表例にとる理由である.

3 補助変数の生成時と観測時のずれ

3.1 補助変数に生成モデルを置く

本節では補助変数を三つに書き分ける. スロット u は確率変数でも母数でもなく、生成則をもたない (生成則は差し込まれる値の側がもつ). 生成時の値 $u^* \in \{1, \dots, K\}$ は事前分布 $\pi_i = P(u^* = i)$ をもつ確率変数である. 観測時の値 $\tilde{u}$ も確率変数で、 u^* と食い違いうる. 真の生成はスロットに u^* を、本稿の分析者は $\tilde{u}$ を差し込む.

ずれは $K \times K$ の行確率行列 Λ ($\Lambda_{ij} = P(\tilde{u} = j | u^* = i)$) で表す. これが §1 の遷移確率行列 (通信路) である. 理論の側が、観測時の値から生成時の値を推すベイズ反転

$$\tilde{\Lambda}_{ji} = P(u^* = i | \tilde{u} = j) = \pi_i \Lambda_{ij} / q_j \quad (6)$$

を用いる. ここで $q_j = \sum_i \pi_i \Lambda_{ij}$ である. 行列で書けば $\tilde{\Lambda} = D_q^{-1} \Lambda^\top D_\pi$ となる ($D_\bullet$ は対角行列).

iVAE は各標本に補助変数の値を一つしかもたず、両者の食い違いを表せない. そこで本稿は、対 $(u^*, \tilde{u})$ に生成モデル

$$p(u^*, \tilde{u}) = \pi_{u^*} \Lambda_{u^* \tilde{u}} \quad (7)$$

を置く. スロットに差し込む値は、標本ごとの属性として既に分布をもつ (iVAE はそれを用いないだけである).

従来との差分は、この対に同時分布を与え、生成時と観測時のずれを確率変数として扱ったことにある。通信路はこの生成モデルの一分成分であって、出発点ではない。

この生成モデルはモデル化の向きも固定する。本稿の同時分布は

$$p(u^*, \tilde{u}, z, x) = \underbrace{\pi_{u^*} \Lambda_{u^* \tilde{u}}}_{(\pi, \Lambda)} \underbrace{p_{T, \lambda}(z | u=u^*) p(x | z)}_{\theta=(f, T, \lambda)} \quad (8)$$

となる。すなわち u^* を最初に引き、一方は通信路を通して $\tilde{u}$ へ、他方はスロットを経て z へ、さらに f を通って x へ向かう。 θ には π も Λ も含まれない。須子・堀井 [12] も母数を同様に分けて書いているが、 Λ を既知として補正する。本稿は Λ を未知のまま補正しない。

ただし、観測の過程が x を参照する場合（人の判定が典型）、実態はしばしば逆向きの $p(\tilde{u} | x)p(x)$ に近い。この向きでは誤りは標本に依存し、入力を u^* とする行列 Λ という対象が立たない。本稿の結果は式 (8) の向きの下での主張である。逆向きは枠組みの外にある。

ここまで、属性の種類を限らずに述べてきた。以下では代表例のクラスラベルの語で書き、 u^* を真のラベル、 $\tilde{u}$ を観測ラベル、 u^* の値をクラスと呼ぶ。以降の結果は、ラベルに固有の性質を使わない。ただし他の属性に適用するときは、仮定 1 のクラス条件付き性がその観測の機構で成り立つかを確かめる必要がある。

例 3 (対称通信路)。確率 ρ で誤り、誤れば残り $K-1$ クラスへ等確率に散る通信路は

$$\Lambda = (1 - \rho)I + \frac{\rho}{K-1}(\mathbf{1}\mathbf{1}^\top - I), \quad \rho \in [0, 1] \quad (9)$$

となる。

3.2 分析者は通信路を補正しない

本稿の設定を次の仮定で明示する。

仮定 1 (補正なし条件づけ)。分析者は $(x, \tilde{u})$ のみを観測し、 u^* , π , Λ は未知である（見えるのは $\tilde{u}$ の分布 $q = \Lambda^\top \pi$ までである）。分析者は Λ を推定も補正もせず、スロットに $\tilde{u}$ をそのまま差し込む。したがって推定の対象は θ だけである。 $(u^*, \tilde{u}, z, x)$ は式 (8) に従い、ノイズはクラス条件付き（class-conditional noise, CCN: $\tilde{u} \perp z | u^*$ ）とする。すなわち $\tilde{u}$ の親は u^* だけである。観測時の誤りは z にも x にも依存しない。また $\pi_i > 0$, $q_j > 0$ とする。

CCN が破れると通信路が $\Lambda(x)$ となり、以降の議論が立たない。CCN は、解析を閉じるための理想化として置く。成り立つかは属性の種類ではなく、観測の機構が x を参照するかで決まる。人の判断を経たラベルでは、CCN は近似にとどまる。時計のずれや識別子の誤記のように x を参照しない機構では、式 (8) の下で構成から成り立つ。ただし区間番号では区間内で z が連続に動くので、境界付近の標本ほど隣の区間へ誤記されやすく、CCN は破れる。ラベルでの破れは §5.2 で測る。

この設定は、通信路を補正する枠組みとも異なる。Hu[13] や Miao ら [14] の枠組みでは補正する側が通信

路を補正するため、識別には Λ の可逆性（フルランク）が要る。補正しない本稿の設定では、完全崩壊は Λ のランクが 1 のときにしか起きない。同時に、 Λ のランクが $d+1$ に届かない段階で、擬似真値における十分変動性は既に成り立たない (§5.1)。

3.3 既存の定理が使えないこと

既存の定理を適用できないことを、次の補題で確認する。

補題 4. 仮定 1 の下で、

$$p^*(z | \tilde{u} = j) = \sum_{i=1}^K \tilde{\Lambda}_{ji} p^*(z | u=i) \quad (10)$$

となる。ここで p^* は真の分布である。右辺の各項は式 (3) の族に属する。 $\tilde{\Lambda}$ の第 j 行が指示ベクトルでない限り、左辺は一般に族の外に出る。

式 (10) は全確率の公式と CCN から従い、 z が連続なら指数族は一般に混合について閉じない（例： $0.9\mathcal{N}(0, 1) + 0.1\mathcal{N}(1, 1)$ は正規分布でない）。

補題 4 より、分析者のモデルは生成過程を正しく記述しない。また、 $\tilde{u}$ で条件づけた自然パラメータが定義できないので、 L を $\tilde{u}$ の側へ転写できず、定理 2 は使えない。そこで本稿は、識別可能性の厳密な保存ではなく、誤特定下の擬似真値の構造を問う。いま、分析者の母集団対数尤度とその最大化点を

$$\ell(\theta) = \mathbb{E}_{p^*}[\log p_\theta(x | \tilde{u})], \quad \theta^\dagger = \arg\max_{\theta} \ell(\theta) \quad (11)$$

と書き、 $\theta^\dagger$ を擬似真値と呼ぶ [4]。誤りのない場合 ($\Lambda = I$) には誤特定が消え、真の母数 θ^* に対し $\theta^\dagger \sim_A \theta^*$ となる。

4 主定理

解析を閉じた形で行うため、式 (11) の最大化を、 z を直接観測したとみなす潜在層の最大化で置き換え、次の作業モデルを置く。

仮定 2 (作業モデル)。真の生成を $z | u^*=i \sim \mathcal{N}(\mu_i, \sigma^2 I)$ とし ($\sigma^2 > 0$, μ_i は相異なる)、分析者のモデル族は観測ラベルごとの平均 η_j と共有の分散 $s^2 I$ をもつ正規分布とする。

共有分散は基底測度に吸収されるので、 $k=1$ となる。以下では仮定 1, 2 を置く。このとき、次の命題が成り立つ。

命題 5. 擬似真値の観測ラベルごとの平均は

$$\eta_j = \sum_i \tilde{\Lambda}_{ji} \mu_i \quad (12)$$

となる (j は観測ラベル、 i は真のラベル)。これは Λ の対称性、 π の一様性、 σ^2 に依存しない。

停留条件 $\eta_j = \mathbb{E}[z | \tilde{u} = j]$ に式 (10) を代入すれば得られる。分析者の平均は、真のクラス平均を事後確率 $\tilde{\Lambda}_{j\cdot}$ で重みづけた平均である。

観測ラベルごとの真の潜在分布の差の一次結合全体を

$$\mathcal{D} = \text{span}\{p^*(\cdot | \tilde{u}=j) - p^*(\cdot | \tilde{u}=j')\} \subset L^2(\mathbb{R}^d) \quad (13)$$

とする。 $\mathcal{D}$ は、 $\tilde{u}$ が潜在変数の分布を何次元動かせるかを表す。このとき、以下の定理が成り立つ。

定理 6 (主定理). 仮定 1, 2 の下で

$$\dim \mathcal{D} = \text{rank } \Lambda - 1 \quad (14)$$

が成り立つ。

証明は二段からなる（紙面の都合で略す）。 $\tilde{\Lambda}$ の行どうしの差の一次結合全体がなす空間は $r - 1$ 次元であり（ $r = \text{rank } \Lambda$ ），相異なる μ_i をもつガウス密度は関数として一次独立である。後者は μ の幾何を使わないので、 μ_i が一直線上でも $d < K - 1$ でも主定理は成り立つ。 μ の重複を許した厳密な形は、同じ成分を束ねる指示行列 S による $\dim \mathcal{D} = \text{rank}(\tilde{\Lambda}S) - 1$ である。この形は補助変数の失敗を、属性が z を動かさないこと（ μ の重複）と、生成時と観測時の値のずれ（ Λ のランク落ち）とに分ける。上界 $\dim \mathcal{D} \leq \text{rank } \Lambda - 1$ は μ によらず成り立つ。主定理から、次の系が従う。

系 7 (完全崩壊). (1) $\dim \mathcal{D} = 0$, (2) $\text{rank } \Lambda = 1$, (3) $\tilde{\Lambda}$ の全行が一致する（共通行は π ），(4) 相互情報量 $I(u^*; \tilde{u}) = 0$ は同値である。このとき擬似真値の事前分布は $\tilde{u}$ によらない定数となり、分析者のモデルは事前分布を条件づけない VAE と同じ族になる。

(2)–(4) の同値は π によらないので、崩壊点は通信路容量が 0 になる点として特徴づけられる。ただし崩壊の手前の挙動は π に依存する。

5 主定理以降の結果と実験

実験 A はニューラルネットワークを用いず、ランクを指定した通信路で主定理と命題 8 の次元を計算する。対称通信路はランクが K か 1 の二択なので（系 10 ），主定理の検証には使えないからである。実験 B は iVAE を実際に学習し、事前分布のクラス平均が系 10 と命題 5 の予言どおりに縮むかを測る。動機である気圧配置分類は、ラベル自体の曖昧さと入力特徴量の不足を分離できないので実証に用いない。また、理論は事前分布側の量を予言し、seed 間の潜在表現の一致度（MCC）は対象としない。

5.1 実験 A：データ側の次元と分析者が表せる次元

主定理は、識別可能性が保たれることを意味しない。 $\mathcal{D}$ は真の分布だけで決まるデータ側の量で、分析者のモデル族を含まないからである。識別可能性は、作業モデルがその違いを何次元表せるかに制約される。この次元は、主定理を用いずに次の命題で与えられる。

命題 8 (作業モデルが表せる次元). M を第 i 行が $\mu_i^\top$ の行列、 $a = \dim \text{aff}\{\mu_i\}$, $r = \text{rank } \Lambda$, $\mathcal{C} = \text{span}\{\eta_j - \eta_{j'}\}$ とすると

$$\dim \mathcal{C} = \text{rank}((\Lambda - \mathbf{1}q^\top)^\top D_\pi M) \leq \min(r - 1, a) \quad (15)$$

となり、 μ が一般の位置にあれば等号が成り立つ。また $a \leq \min(d, K - 1)$ である。




図 1: 実験 A ($K = 10$, $d = 8$, 閉形式)。横軸は通信路 Λ のランク。○はデータ側の $\dim \mathcal{D}$, ■は分析者側の $\dim \mathcal{C}$ 。網掛けの $\text{rank } \Lambda < d + 1$ では擬似真値での十分変動性が成り立たない ((b) では外側でも)。 (a) μ_i が一般の位置, (b) 一直線上。破線は $r - 1$, 点線は d 。

等式は式 (12) から、上界は Λ の行の差の次元 $r - 1$ と、 η_j が $\{\mu_i\}$ のアフィン結合であることから出る。

$K = 10$, $d = 8$ とし、 Λ をランクがちょうど r になるように構成して、 η_j を閉形式で計算する。 $\dim \mathcal{D}$ はガウス密度 ($\sigma^2 = 0.25$) の L^2 内積によるグラム行列の数値ランクとして、 $\dim \mathcal{C}$ は差 $\eta_j - \eta_1$ を並べた行列の数値ランクとして測り、構成から既知の r と照合する。

図 1 より、 $\dim \mathcal{D}$ は μ の配置によらず全点で $r - 1$ に等しい（主定理。 $r = 1$ は系 7 の完全崩壊）。一方、 $\dim \mathcal{C}$ は $\min(r - 1, a)$ で頭打ちになる（命題 8）。ランク 10（ずれがない $\Lambda = I$ を含む）でも 9 対 8、 μ が一直線上なら 9 対 1 である。データ側に違いが残ることと、分析者がそれを表せることは別である。 μ の間隔を詰めてガウス核の条件数を最大 1.61×10^9 まで悪化させても、 $\dim \mathcal{D} = r - 1$ は保たれた。よって主定理の等式は、そのままでは識別可能性の条件を与えない。

擬似真値は真の混合分布と異なり族の内側にあり、自然パラメータ $\lambda^\dagger(j) = \eta_j / s^2$ をもつ。そこで式 (5) にならない、観測ラベルの相異なる値 $j_0, \dots, j_d$ で $L^\dagger = [\lambda^\dagger(j_i) - \lambda^\dagger(j_0)]_{i=1}^d$ とおく。ある選び方で $L^\dagger$ が正則になることは、 $\dim \mathcal{C} = d$ と同値である。よって $d \leq K - 1$ なら、一般の位置では $\text{rank } \Lambda \geq d + 1$ がその必要十分条件となる（ $d > K - 1$ では $\dim \mathcal{C} = d$ に到達しない）。以上から、次の系を得る。

系 9 (通信路のランクが足りないとき). $1 < \text{rank } \Lambda < d + 1$ のとき、 $I(u^*; \tilde{u}) > 0$ であるが擬似真値における十分変動性（ $L^\dagger$ の正則性）は成り立たない。

また $d \in \{2, 4, 6, 8, 9\}$ でそれぞれ (π, μ, Λ) を 100 組抽出すると、 $\dim \mathcal{C} = d$ に要する最小のランクは 100 組すべてで $d + 1$ であった。 $d = 12 > K - 1$ ではどのランクでも到達しなかった (0/100)。

「 $I(u^*; \tilde{u}) = 0$ なら崩壊する」は真だが、「 $I(u^*; \tilde{u}) > 0$ なら十分変動性が成り立つ」は偽である。ただし十分変動性は定理 2 の十分条件にすぎないので、その破れから識別不能は結論できない。識別不能を主張できるのは完全崩壊の場合だけである。設計の側から読むと、

$\text{rank } \Lambda \geq d + 1$ は

$$d \leq \text{rank } \Lambda - 1 \quad (16)$$

となる。すなわち、通信路 Λ のランクが、安全に設定できる潜在次元の上限を与える。 Λ のランクは、行の一次結合全体がなす空間の次元である。誤り率だけでは定まらない。ランク落ちを解消するには、行が一致するか、他の行の一次結合で書けるクラスの組を分離することになる。ただし $\text{rank } \Lambda$ を真のラベルなしに得る手段は本稿がなく、これは判定手続きではない。

効くのが誤り率でも相互情報量でもなく Λ のランクであることは、一様な π 、一般の位置の μ での次の比較で見える。2 組のクラス対それぞれで対の 2 値を等確率で出す通信路（誤り率 0.2, $I(u^*; \tilde{u}) = 2.92$ bit）は、ランクが 8 で $\dim C = 7 < d$ となり、擬似真値での十分変動性を満たさない（系 9）。これに対し、対称通信路 $\rho = 0.6$ (0.45 bit) はランクが 10 で $\dim C = 8 = d$ となる。

5.2 実験 B：学習した iVAE の事前分布

例 3 の対称通信路では、次を得る。

系 10 (対称通信路). $\gamma(\rho) = 1 - K\rho/(K - 1)$, $\rho^* = (K - 1)/K$ とおく。 Λ は対称で、その固有値は 1 と $\gamma(\rho)$ (重複度 $K - 1$) なので、 $\text{rank } \Lambda$ は $\rho \neq \rho^*$ で K , $\rho = \rho^*$ で 1 となる。さらに π が一様で $\sum_i \mu_i = 0$ なら、 $\eta_j(\rho) = \gamma(\rho)\mu_j$ となる。

よって対称通信路族では崩壊は ρ^* の一点でのみ起き、 $d \leq K - 1$ なら系 9 の中間の場合も起きない。一般の通信路では η_j が μ_j の定数倍にならないので、平均対距離の比

$$\gamma_{\text{pair}} = \frac{\text{mean}_{j < j'} \|\eta_j - \eta_{j'}\|}{\text{mean}_{i < i'} \|\mu_i - \mu_{i'}\|} \quad (17)$$

を残存率とする。これは回転と全体の尺度によらず、対称通信路、一様な π 、中心化の下では $|\gamma(\rho)|$ に等しい。すなわち系 10 は、残存率が誤り率とともに直線的に減り、 ρ^* で 0 に達し、その先では再び増えることを予言する。

CIFAR-10 の学習 12000 枚・検証 3000 枚で、 $K = 10$, $d = 8$ の iVAE を 6 seed ずつ学習した。エンコーダは x のみを入力とし、 $\tilde{u}$ は事前分布の自然パラメータを出す部分 (θ に含まれる) にだけ入る。事前分布の対数分散は $\tilde{u}$ に依存させず、作業モデルの $k = 1$ に揃えた。測る量は式 (17) の γ_{pair} である。 μ_i は観測できないので、同じ seed で $\tilde{u} = u^*$ として学習した事前分布のクラス平均 $\hat{\mu}_i$ を代理に用いる。したがって以下は命題の厳密な検証ではなく代理による当てはめである。この比は二つの座標系が相似変換で結ばれる場合にしか $\sim_A$ 不変ではない。CIFAR-10 の元ラベルを u^* とみなすが、それ自体も人の注釈に由来するので、これは仮定である。

対称通信路. $\tilde{u}$ は x を参照せず、元ラベル u^* から式 (9) の通信路で引いた (CCN は構成から成り立つ)。 ρ を 10 点とり、計 60 回学習した。図 2 の $\circ$ より、残存率は




図 2: 実験 B (CIFAR-10, $k = 1$, 6 seed). 縦軸はクラス平均の残存率 γ_{pair} . 実線は対称通信路の理論 $|\gamma(\rho)|$ (系 10). $\circ$ は元ラベルに対称ノイズを載せて学習した実測 (平均と、6 seed のパーセンタイル・ブートストラップによる 95% 信頼区間。学習画像の集合は seed 間で共通)、網掛けは ρ^* での実測の信頼区間。 $\blacklozenge$ は CIFAR-10N の人手ラベル 5 条件の実測 (誤差棒は seed の標準偏差)、 $\triangle$ はその推定通信路 $\hat{\Lambda}$ と $\hat{\mu}$ から命題 5 で計算した予測。 $\blacklozenge$ と $\triangle$ の横軸は学習分割での実効誤り率。

$\rho \leq 0.7$ で理論の直線に沿って落ちるが (差は最大 0.032), $\rho = 0.4, 0.5, \rho \geq 0.8$ では理論値が $\circ$ の信頼区間の外にある。実測は $\rho^* = 0.9$ で最小の 0.088 [0.082, 0.094] をとり、その先では再び増える ($\rho = 1$ で 0.147)。 ρ^* では観測ラベルが真のラベルと独立なので理論値は 0 である。実測の 0.088 は有限標本による底である。理論値がこの底を下回る ρ^* の近傍では、実測は底の近くにとどまる。崩壊点の位置と、その先で縮みが戻ることは、学習した事前分布でも系 10 の予言どおりに現れた。

実通信路. CIFAR-10N[3] の人手ラベル 5 条件 (3 票の多数決 aggreg, 各 1 票 random1-3, 最悪の 1 票 worse) を $\tilde{u}$ とし、通信路 $\hat{\Lambda}$ を計数で推定した (学習分割の実効誤り率 0.088-0.399)。図 2 より、実効誤り率だけから対称通信路として計算した予測 (実線上の値) は、5 条件すべてで実測を下回る。推定通信路による命題 5 の予測に置き換えると、実測との平均絶対誤差は 0.0957 から 0.0222 へ縮む (両者の比 4.31, 95% 信頼区間 [2.83, 6.95]。 $k = 2$ で 7.23)。誤りはクラス平均の近い対に集中しており (誤り質量と $\hat{\mu}_i$ 間距離の Spearman 相関 -0.46--0.75), そのぶん一様に散る場合より縮みが小さい。実測と予測の差の 95% 信頼区間は, worse (+0.053 [+0.019, +0.080]) だけ 0 を含まない。なお 5 条件は同一の 3 組の注釈に由来し、独立な 5 回の検定ではない。また計数推定した $\hat{\Lambda}$ の数値ランクは常に 10 なので、この実験で $\text{rank } \Lambda \geq d + 1$ による判定は確かめられない。

最後に CCN を検定した。 ($u^*, \tilde{u}$) を固定して真のラベルの内側で潜在表現を置換し、 $\tilde{u}$ の z への依存だけを壊した帰無分布と比べる。統計量は、観測ラベルごとの潜在平均と命題 5 の予測との距離を、真のラベルごとの潜在平均間の平均対距離で割り、観測ラベルについて平

均した残差である。学習分割で $p < 0.05$ となった seed 数は、上の 5 条件の順に $k = 1$ で 0/6, 6/6, 4/6, 6/6, 6/6, $k = 2$ で 1/6, 5/6, 5/6, 6/6, 6/6 であった。検証分割では $k = 1$ で 0/6, 0/6, 0/6, 6/6, 6/6, $k = 2$ で 0/6, 0/6, 0/6, 6/6, 4/6 であり、棄却数は学習分割以下である。seed ごとの検定に多重性の補正はしておらず、この差への過適合と検出力の寄与は分けていない。帰無分布の平均に対する残差の比の seed 平均は、 $k = 1$ の学習分割で 1.14–1.34, 検証分割で 0.96–1.26 であった。

5.3 前提への依存

以上の主張は、依存する前提によって三つに分かれる。(i) 系 7 の (2)–(4) の同値と容量による特徴づけは、通信路の代数だけで成り立つ。別の通信路 Λ' を後段に重ねても、 $\text{rank}(\Lambda\Lambda') \leq \text{rank} \Lambda$ よりランクは回復しない。(ii) 残りの結果は、補題 4 を通じて式 (8) の向きと CCN に依存する。CCN が成り立たなくても、(i) は影響を受けない。(iii) 命題 5, 8, 系 10 の平均の閉形式と $L^\dagger$ による評価は、さらに作業モデルに依存する。主定理は作業モデルのうち、成分密度 $p^*(z | u=i)$ が関数として一次独立であることだけを用いる。また、系 10 だけが対称通信路に限られ、他は Λ の形を問わない。

6 まとめと今後の課題

本稿は補助変数の生成時の値と観測時の値の対に生成モデルを置き、補正なし条件づけの下で、観測ラベルごとの潜在分布の差の一次結合全体がなす空間の次元が $\text{rank} \Lambda - 1$ に等しいことを示した (定理 6)。完全崩壊は $I(u^*; \tilde{u}) = 0$ のときに限り起きる。

一方、学習を繰り返しても潜在空間がアフィン変換を除いて同じものに定まるという意味での識別可能性は、擬似真値の観測ラベルごとの平均の差の一次結合全体がなす空間 C が縛る (命題 8)。rank Λ が $d + 1$ に届かなければ、観測ラベルに真のラベルの情報が残っていても擬似真値における十分変動性は成り立たない。

本稿の結果には、以下の限界がある。

- 主定理は潜在層の作業モデルに閉じており、デコーダの非線形性、対数周辺尤度とその下界 ELBO の差、有限標本の効果を含まない。実際の iVAE の擬似真値が潜在層の擬似真値と一致するかは別途議論を要する。実験 B の worse で予測と実測の差の信頼区間が 0 を含まないのは、この食い違い、CCN の破れ、代理 $\hat{\mu}_i$ の誤差のいずれかに由来しうる (これらは分離していない)。
- 作業モデルは $k = 1$ 、実験のエンコーダは $q_\phi(z | x)$ であり、[2] の実装 ($k = 2$, $q_\phi(z | x, u)$) とは異なる。実験 B は $k = 1$ に揃えており、 $k = 2$ でも改善の向きは変わらない。
- CCN は理想化であり、実データでは成り立っていない。CCN を外したときに崩壊の記述がどれだけ変わるかは測っておらず、CCN を有効な近似とは主張しない。ラベル以外の属性での点検も、 Λ が x に依存する場合やソフトラベルへの拡張も行っていない。

- rank Λ と π は分析者に未知であり、真のラベルなしにこれらを得る手段は与えていない。計数推定した $\hat{\Lambda}$ の数値ランクは常に K であり、 $\text{rank} \Lambda \geq d + 1$ の判定には使えない。図 1 は閉形式の計算であり、学習済みモデルの D は測っていない。
- 誤特定の下で、観測ラベルで条件づけた族と定義 1 の族との関係は定式化していない。
- 主定理は潜在変数が有限台をとる族には一般化できず、補助変数によらず x の復元の項だけで学習間の表現が一致する現象も扱わない。

工学的には、判定に用いるべき量は誤り率ではなく通信路 Λ のランクである。このランクは設定できる潜在次元の上限を与える。ただし、判定の手続きは今後の課題である。

参考文献

- [1] A. Hyvärinen and P. Pajunen, “Nonlinear independent component analysis: Existence and uniqueness results,” *Neural Networks*, vol. 12, no. 3, pp. 429–439, 1999.
- [2] I. Khemakhem, D. P. Kingma, R. P. Monti, and A. Hyvärinen, “Variational autoencoders and nonlinear ICA: A unifying framework,” in *Proc. 23rd AIS-TATS*, pp. 2207–2217, 2020.
- [3] J. Wei, Z. Zhu, H. Cheng, T. Liu, G. Niu, and Y. Liu, “Learning with noisy labels revisited: A study using real-world human annotations,” in *Proc. ICLR*, 2022.
- [4] H. White, “Maximum likelihood estimation of misspecified models,” *Econometrica*, vol. 50, no. 1, pp. 1–25, 1982.
- [5] D. Blackwell, “Equivalent comparisons of experiments,” *Ann. Math. Statist.*, vol. 24, no. 2, pp. 265–272, 1953.
- [6] V. C. Raykar and S. Yu, “Eliminating spammers and ranking annotators for crowdsourced labeling tasks,” *JMLR*, vol. 13, pp. 491–518, 2012.
- [7] D. Angluin and P. Laird, “Learning from noisy examples,” *Machine Learning*, vol. 2, no. 4, pp. 343–370, 1988.
- [8] C. E. Priebe, N. Huang, S. Villar, C. Mu, and L. Chen, “Deep learning is provably robust to symmetric label noise,” arXiv:2210.15083, 2022.
- [9] E. S. Allman, C. Matias, and J. A. Rhodes, “Identifiability of parameters in latent structure models with many observed variables,” *Ann. Statist.*, vol. 37, no. 6A, pp. 3099–3132, 2009.
- [10] H. Saad and A. Nosratinia, “Community detection with side information: Exact recovery under the stochastic block model,” *IEEE J. Sel. Topics Signal Process.*, vol. 12, no. 5, pp. 944–958, 2018.
- [11] A. Hyvärinen, I. Khemakhem, and H. Morioka, “Nonlinear independent component analysis for principled disentanglement in unsupervised deep learning,” *Patterns*, vol. 4, no. 10, Art. no. 100844, 2023.
- [12] 須子統太, 堀井俊佑, “一般化ラベルノイズモデルにおける分類問題について,” 信学技報, IBISML2017-87, pp. 377–382, Nov. 2017.
- [13] Y. Hu, “Identification and estimation of nonlinear models with misclassification error using instrumental variables: A general solution,” *J. Econometrics*, vol. 144, no. 1, pp. 27–61, 2008.
- [14] W. Miao, Z. Geng, and E. J. Tchetgen Tchetgen, “Identifying causal effects with proxy variables of an unmeasured confounder,” *Biometrika*, vol. 105, no. 4, pp. 987–993, 2018.